Resultados iniciales del algoritmo (antes de agregarlo a la tesis)

Nuestro problema es

$$\begin{aligned} \min_{x\in\mathbb{R}^n} \quad & \frac{1}{2}\, x^T Q x + c^T x \\ \text{s.a.} \quad & Ax - b = \mathbf{0}_m, \\ & Fx - d \geq \mathbf{0}_p \end{aligned} \tag{P1}$$

donde $f(x) = \frac{1}{2}x^T Q x + c^T x$, $g(x) = Fx - d$ y $h(x) = Ax - b$, y adicionalmente tiene las siguientes características:

$$\begin{aligned} & Q \in \mathbb{R}^{n\times n},\ \text{simétrica y } Q \text{ es definida positiva, i.e. } Q \succ 0, \quad c \in \mathbb{R}^n, \\ & A \in \mathbb{R}^{m\times n},\ \text{rank}(A) = m, \quad b \in \mathbb{R}^m,\ m \leq n, \\ & F \in \mathbb{R}^{p\times n}, \quad d \in \mathbb{R}^p \end{aligned}$$

Las holguras son $z = Fx - d \in \mathbb{R}^p$ ($z \geq \mathbf{0}_p$), los multiplicadores $\lambda \in \mathbb{R}^m$ para igualdad y $\mu \in \mathbb{R}^p$ ($\mu \geq \mathbf{0}_p$) para desigualdad. Complementariedad: $\mu_j z_j = 0$ para todo j.

Con $D_\mu = \text{diag}(\mu)$, $D_z = \text{diag}(z)$, y el cambio de variable $D_\mu^{-1}\delta_\mu$, el sistema reducido $(n+m+p)$ que resolvemos cada iteración es:

$$\underbrace{\begin{pmatrix} Q & -A^T & -F^T D_\mu \\ -A & \mathbf{0}_{m\times m} & \mathbf{0}_{m\times p} \\ -D_\mu F & \mathbf{0}_{p\times m} & -D_z D_\mu \end{pmatrix}}_{K} \begin{pmatrix} \delta_x \\ \delta_\lambda \\ D_\mu^{-1}\delta_\mu \end{pmatrix} = -\underbrace{\begin{pmatrix} Qx + c - A^T\lambda - F^T\mu \\ -Ax + b \\ D_\mu(d - Fx) + \tau e \end{pmatrix}}_{L} \tag{K}$$

HELLO Para resolver el sistema $K\delta = -L$ en cada iteración se utiliza `scipy.linalg.solve`, que maneja de forma robusta sistemas cercanos a la singularidad emitiendo un aviso cuando el condicionamiento es alto.

Para poder evaluar si la detección funciona, necesitaba saber cuáles μ_i realmente tienden a cero, pero sin usar mis propios criterios como respuesta. Lo que hice fue usar Clarabel[1] como solver independiente. Lo elegí porque está disponible a través de la librería `qpsolvers` de Python y, al ser también un método de puntos interiores, me da confianza de que la solución sea numéricamente compatible con lo que nuestro IPM intenta aproximar (pero por favor dime si esto no es correcto). Clarabel se destaca por atacar los problemas de precisión numérica combinando técnicas como la factorización de Cholesky para resolver el sistema KKT de forma estable y el esquema predictor-corrector de Mehrotra para acelerar la convergencia. Además, es de código abierto (*open-source*) y es accesible desde Python a través de la librería `qpsolvers`.

Con `solve_problem` obtengo tanto la holgura z^* como el multiplicador dual μ^*. Por complementariedad estricta, al menos uno de los dos tiende a cero en la solución óptima. Para clasificar, uso el cociente z_i^*/μ_i^*: si $z_i^*/\mu_i^* > 100$, la holgura domina y $\mu_i \to 0$ (restricción inactiva); si $z_i^*/\mu_i^* < \frac{1}{100}$, el dual domina y $z_i \to 0$ (restricción activa). Este criterio es libre de escala y no depende de un umbral absoluto. Adicionalmente, se verifica que $\mu_i^* < z_i^*$ como confirmación de que el multiplicador dual es la variable que tiende a cero.

[1] Goulart, P. J. y Chen, Y. (2024). "Clarabel: An Interior-Point Solver for Conic Programs with Quadratic Objectives". arXiv:2405.12762.

Problemas benchmark

Probé con 9 problemas de dos conjuntos estándar: Maros & Meszaros[2] y Hock & Schittkowski[3]. Los valores de referencia de los HS son analíticos (del libro); los de Maros-Meszaros son los que reportan los autores (obtenidos con un solver de puntos interiores).

Table 1: Problemas benchmark y valores de referencia.

Problema	n	m	p	f^* publicado	Fuente
TAME	2	1	2	0	Maros & Meszaros 1999
HS21	2	0	5	-99.96	Hock & Schittkowski 1981
HS35	3	0	4	$\frac{1}{9}$	Hock & Schittkowski 1981
HS53	5	3	10	$\frac{176}{43}$	Hock & Schittkowski 1981
DUAL1	85	1	170	0.03501297	Maros & Meszaros 1999
DUAL2	96	1	192	0.03373368	Maros & Meszaros 1999
DUAL3	111	1	222	0.13575584	Maros & Meszaros 1999
DUAL4	75	1	150	0.74609084	Maros & Meszaros 1999
QPCBLEND	83	43	114	-0.00784254	Maros & Meszaros 1999

Primero verifiqué que Clarabel coincida con los valores publicados. Para esto usé `solve_problem` de `qpsolvers`, que devuelve un objeto `Solution` con la solución primal x, los multiplicadores duales z (desigualdad) e y (igualdad), y el valor objetivo `sol.obj`. Coincide en todos los casos (diferencias del orden de 10^{-9} o menos):

Table 2: Clarabel vs valores publicados, y clasificación de restricciones según cociente z_i^*/μ_i^*.

Problema	f^*(Clarabel)	f^*(publicado)	|dif|	$\mu \to 0$	% elim
TAME	0.0000000000	0.0000000000	0	2	100%
HS21	-99.9599999991	-99.9600000000	8.9×10^{-10}	4	80%
HS35	0.111111183	0.111111111	7.2×10^{-9}	3	75%
HS53	4.0930232558	4.0930232558	8.9×10^{-16}	10	100%
DUAL1	0.035012968	0.035012960	2.8×10^{-9}	147	86%
DUAL2	0.033733676	0.033733676	2.4×10^{-10}	188	98%
DUAL3	0.135755837	0.135755840	2.1×10^{-9}	205	92%
DUAL4	0.746090841	0.746090840	1.9×10^{-9}	136	91%
QPCBLEND	-0.007842542	-0.007842540	1.1×10^{-9}	67	59%

Detección

Como habíamos planteado, clasifico cada μ_i como $\to 0$ cuando se cumplen cuatro criterios simultáneos:

1. $\mu_i z_i \leq 10^{-5}$ (tolerancia de complementariedad),
2. μ_i decreció respecto a la iteración anterior,
3. el cambio porcentual de z_i es > -0.03, i.e., z_i se mantiene aproximadamente constante,

[2]Maros, I. y Meszaros, C. (1999). "A Repository of Convex Quadratic Programming Problems". *Optim. Methods Softw.*, 11(1–4), 671–681. DOI: 10.1080/10556789908805768. Archivos `.mat`: github.com/YimingYAN/QP-Test-Problems.

[3]Hock, W. y Schittkowski, K. (1981). *Test Examples for Nonlinear Programming Codes*. Lecture Notes in Economics and Mathematical Systems, vol. 187, Springer. DOI: 10.1007/978-3-642-48320-2.

4. **(nuevo)** indicador de Tapia: $\mu_i^{(k)}/\mu_i^{(k-1)} < 0.8$ (ver más abajo).

Con los cuatro criterios activos, solo QPCBLEND presenta 1 falso positivo (una restricción con $z_i^*/\mu_i^* \approx 0.64$, genuinamente ambigua); los demás problemas tienen 0 FP.

Table 3: Detección del IPM (4 criterios simultáneos) vs clasificación de Clarabel.

Problema	Iter	$\mu \to 0$ real	Detectados	Sensib.	FP	$\|x - x^*\|_\infty$
TAME	6	2	2	100%	0	1.1×10^{-16}
HS21	11	4	4	100%	0	8.7×10^{-8}
HS35	7	3	3	100%	0	5.6×10^{-8}
HS53	8	10	10	100%	0	2.2×10^{-11}
DUAL1	15	147	140	95%	0	3.8×10^{-5}
DUAL2	13	188	185	98%	0	1.0×10^{-5}
DUAL3	14	205	202	99%	0	2.5×10^{-5}
DUAL4	12	136	136	100%	0	1.8×10^{-5}
QPCBLEND	22	67	63	94%	1	6.0×10^{-5}

Sensib. = Detectados / $\mu \to 0$ real. FP = restricciones activas clasificadas incorrectamente como $\mu \to 0$.

Condicionamiento

Acá se ve la mejora en condicionamiento al eliminar las filas/columnas detectadas, y se comparan los valores óptimos obtenidos con K y $\hat{K}$ contra el valor publicado.

Table 4: Condicionamiento y precisión: K completo vs $\hat{K}$ eliminado (1 iteración) y $\hat{K}$ con 3 iteraciones de refinamiento.

Problema	% elim	$\kappa(K)$	$\kappa(\hat{K})$	f^*(pub.)	f^* (K)	f^* ($\hat{K}$)	f^* ($\hat{K}$, 3 it.)
TAME	100%	2.56×10^{9}	5.00×10^{0}	0.0000000000	0.0000000000	0.0000000000	0.0000000000
HS21	80%	3.50×10^{8}	7.50×10^{1}	−99.9600000000	−99.9599999956	−99.9599999956	−99.9599999956
HS35	75%	3.29×10^{9}	7.81×10^{1}	0.1111111111	0.1111111407	0.1111111114	0.1111111111
HS53	100%	2.49×10^{9}	1.28×10^{2}	4.0930232558	4.0930232558	4.0930232558	4.0930232558
DUAL1*	82%	2.73×10^{13}	1.33×10^{12}	0.0350129660	0.0350130209	0.0350130121	0.0350129659
DUAL2*	96%	2.86×10^{14}	8.68×10^{11}	0.0337336760	0.0337336820	0.0337336818	0.0337336761
DUAL3*	91%	7.51×10^{13}	1.43×10^{12}	0.1357558400	0.1357558969	0.1357558964	0.1357558374
DUAL4*	91%	6.42×10^{15}	1.27×10^{10}	0.7460908400	0.7460908640	0.7460908641	0.7460908418
QPCBLEND	56%	1.77×10^{11}	1.69×10^{11}	−0.0078425409	−0.0078420477	−0.0078420155	−0.0078425390

* $\sigma_{\min}(K) < \varepsilon\, \sigma_{\max}(K)$: el número de condición puede no ser confiable por cercanía a singularidad numérica.

Refinamiento con $\hat{K}$

Una vez que el IPM con K completo converge ($\|\text{KKT}\|_\infty < 10^{-7}$), en lugar de detenernos, continuamos iterando pero ahora con $\hat{K}$: el sistema reducido sin las filas y columnas correspondientes a las restricciones detectadas como $\mu_i \to 0$. Este sistema está mejor condicionado, y en pocas iteraciones la norma KKT baja varios órdenes de magnitud y el valor objetivo se acerca mucho más al publicado.

El número de iteraciones de refinamiento no se fija de antemano: se usa un criterio de paro automático que detiene el refinamiento cuando la mejora en $\|\text{KKT}\|_\infty$ cae por debajo de 1.5× durante 2 iteraciones consecutivas. Es decir, si $\hat{K}$ dejó de ayudar, dejamos de iterar. En la práctica esto resulta en 2–7 iteraciones según el problema.

Para comparar, intenté también continuar con K completo reduciendo la tolerancia, pero en los problemas grandes el error se estanca: por ejemplo, DUAL1 con K completo no baja de $\sim 2.7 \times 10^{-10}$ de error en f^* aun después de 200 iteraciones. Con $\hat{K}$, en pocas iteraciones ya se obtiene precisión comparable a la de Clarabel.

Table 5: Convergencia de la norma KKT al iterar con $\hat{K}$ (criterio de paro: mejora $< 1.5\times$ durante 2 iteraciones consecutivas).

Problema	Iter. $\hat{K}$	$\|\text{KKT}\|_\infty$ (K)	$\|\text{KKT}\|_\infty$ ($\hat{K}$, final)
TAME	—	1.9×10^{-9}	—
HS21	2	7.3×10^{-9}	7.3×10^{-9}
HS35	4	3.0×10^{-8}	5.0×10^{-9}
HS53	—	4.8×10^{-9}	—
DUAL1	6	4.1×10^{-8}	4.3×10^{-10}
DUAL2	5	6.1×10^{-8}	3.0×10^{-10}
DUAL3	6	6.3×10^{-8}	1.5×10^{-9}
DUAL4	7	1.0×10^{-7}	8.4×10^{-12}
QPCBLEND	5	8.5×10^{-8}	1.3×10^{-8}

TAME y HS53 eliminan el 100% de las restricciones y ya alcanzan precisión exacta sin refinamiento. QPCBLEND se estanca en $\sim 10^{-8}$ debido a que solo el 56% de las restricciones se eliminaron.

Table 6: Error en f^* por iteración de refinamiento con $\hat{K}$: $|f^*_{\hat{K}} - f^*_{\text{pub}}|$ en cada paso.

Problema	$\|e\|(K)$	ref 1	ref 2	ref 3	ref 4	ref 5	ref 6	ref 7
HS21	4.4e-9	4.4e-9	4.4e-11					
HS35	3.0e-8	3.0e-8	3.0e-10	3.0e-12	2.7e-13			
DUAL1	5.5e-8	5.5e-8	9.3e-9	1.6e-9	9.4e-11	2.6e-10	2.7e-10	
DUAL2	6.0e-9	6.0e-9	1.8e-10	1.2e-10	1.2e-10	1.2e-10		
DUAL3	5.7e-8	5.7e-8	5.8e-9	1.1e-9	2.6e-9	3.0e-9	3.1e-9	
DUAL4	2.4e-8	2.4e-8	3.9e-9	1.9e-9	1.8e-9	1.8e-9	1.8e-9	1.8e-9
QPCBLEND	4.9e-7	4.9e-7	2.2e-7	1.7e-8	1.7e-9	1.2e-9		

$|e| = |f^*_{\hat{K}} - f^*_{\text{pub}}|$. La primera iteración de refinamiento no mejora el objetivo (el paso se calcula en el mismo punto donde K convergió); la ganancia real comienza en ref 2. TAME y HS53 omitidos (100% eliminación, ya exactos).
Nota: para DUAL1/3, el error sube ligeramente después de ref 4 porque el valor publicado es solver-computed (BPMPD), no analítico; nuestro IPM con $\hat{K}$ puede estar más cerca del óptimo verdadero que el valor de referencia.

Indicador de Tapia (criterio nuevo)

Buscando en internet encontré un artículo de El-Bakry, Tapia y Zhang[4] donde usan el cociente

$$T_i^{(k)} = \frac{\mu_i^{(k)}}{\mu_i^{(k-1)}}$$

para detectar variables que tienden a cero. Entiendo que ellos lo usan para variables primales en programación lineal, pero pensé que podría funcionar igual para nuestras μ_i: si $\mu_i \to 0$ el cociente se queda < 1, y si μ_i se estabiliza el cociente tiende a 1. Lo agregué como criterio 4 con umbral 0.8.

Fun Fact: Tapia fue asesor de Zeferino en el PhD según lo que vi en internet. No sé si sea una mala idea citarlo si Zeferino termina siendo mi sinodal. ._.

[4]El-Bakry, A. S., Tapia, R. A. y Zhang, Y. (1994). "A Study of Indicators for Identifying Zero Variables in Interior-Point Methods". *SIAM Review*, 36(1), 45–72. DOI: 10.1137/1036003.

Table 7: Solo Tapia (sin criterio de estabilidad de z) vs Tapia + estabilidad de z.

	Solo Tapia (sin estab. z)		Tapia + estabilidad de z	
Problema	Sensib.	FP	Sensib.	FP
TAME	100%	0	100%	0
HS21	100%	0	100%	0
HS35	100%	0	100%	0
HS53	100%	0	100%	0
DUAL1	100%	4	95%	0
DUAL2	100%	1	98%	0
DUAL3	100%	5	99%	0
DUAL4	100%	1	100%	0
QPCBLEND	100%	**6**	94%	1

Sin estab. z: criterio de estabilidad de z desactivado, Tapia como único discriminador.
Los 6 FP de QPCBLEND (sin estab. z) se reducen a 1 con estabilidad de z activo.

Sin el criterio de estabilidad de z, aparecen falsos positivos en DUAL1 (2), DUAL3 (3), DUAL4 (1) y QPCBLEND (6). La estabilidad de z los elimina casi todos (queda 1 FP en QPCBLEND, que es una restricción genuinamente ambigua). O sea que el criterio de estabilidad de z es el que más trabaja; Tapia por sí solo no alcanza.

Lo que sí pude ver es que si uso Tapia *solo*, sin estabilidad de z, aparecen 4 falsos positivos en QPCBLEND. O sea que nuestro criterio de estabilidad de z es más fuerte que el de Tapia, y Tapia por sí solo no alcanza.